

Sistema Multi-Agente de Recomendação de Imóveis

Gonçalo Bento, Emerson Neto

*Departamento de Engenharia
Informática Faculdade de Ciências
e Tecnologia Universidade de
Coimbra, Portugal*

{2023108722, [REDACTED]}@student.uc.pt

1 Introdução

A aquisição de um imóvel constitui uma das decisões financeiras e pessoais mais relevantes na vida de um indivíduo. Contudo, o processo atual de pesquisa imobiliária permanece ineficiente e cognitivamente exigente. As plataformas tradicionais baseiam-se em filtros rígidos — como intervalo de preço, tipologia ou localização — que não capturam a subjetividade das preferências humanas. Características como “ambiente sossegado”, “proximidade à natureza” ou “acesso conveniente a serviços” dificilmente podem ser expressas de forma direta, resultando em fadiga decisória e, frequentemente, em recomendações irrelevantes.

Para colmatar estas limitações, este trabalho propõe um Sistema Multi-Agente (SMA) de Recomendação de Imóveis que atua como um consultor imobiliário inteligente. Ao contrário dos motores tradicionais baseados exclusivamente em filtragem exata, o sistema permite interação em linguagem natural, delegando a interpretação das necessidades, a pesquisa e a análise dos imóveis a uma equipa de agentes especializados. A arquitetura adotada segue um paradigma híbrido (neuro-simbólico), combinando a flexibilidade dos Grandes Modelos de Linguagem (LLMs) com a precisão de algoritmos clássicos da Inteligência Artificial.

A solução é orquestrada através da framework Microsoft AutoGen e integra cinco agentes com funções complementares:

1. **Planner Agent**, responsável por extrair intenções e gerar uma representação estruturada das preferências do utilizador;
2. **Location Agent**, encarregado de mapear descrições subjetivas de ambiente para localizações concretas recorrendo a análise semântica e dados meteorológicos;
3. **Property Agent**, responsável pela pesquisa em tempo real através da API do Idealista, aplicando restrições via **Constraint Satisfaction Problems (CSP)** e, quando aplicável, recorrendo ao algoritmo **A*** para estimar a acessibilidade entre cada imóvel e serviços específicos;
4. **Data Analyst Agent**, que utiliza o algoritmo **K-Nearest Neighbors (KNN)** para avaliar matematicamente a similaridade entre imóveis;

5. **Evaluator Agent**, que sintetiza os resultados e produz recomendações explicáveis sob regras estritas de controlo de alucinações.

Os resultados preliminares validam a eficácia da abordagem proposta. Em diferentes cenários de procura — desde arrendamento económico até imóveis de segmento superior — o sistema demonstrou capacidade para interpretar requisitos implícitos, lidar com falhas de inventário através de mecanismos autónomos de fallback e evitar recomendações espúrias típicas de sistemas puramente generativos. A integração das componentes determinísticas — CSP, A* e KNN — contribuiu para recomendações matematicamente consistentes e semanticamente alinhadas com as expectativas dos utilizadores.

Este relatório descreve detalhadamente a arquitetura multi-agente, os componentes algorítmicos, os materiais utilizados, a metodologia experimental e a avaliação qualitativa e quantitativa do sistema desenvolvido.

2 Design do Sistema Multi-Agente

A arquitetura desenvolvida segue o paradigma de Sistemas Multi-Agente (SMA), assentando numa abordagem híbrida neuro-simbólica que combina a interpretação semântica oferecida por Grandes Modelos de Linguagem (LLMs) com a precisão dos algoritmos clássicos de Inteligência Artificial. A implementação é realizada com a framework **Microsoft AutoGen**, que gere a coordenação entre agentes, o fluxo de mensagens e o ciclo de execução segundo um padrão **Round-Robin**.

Todos os agentes comunicam através de mensagens estruturadas e partilham um estado global que contém preferências do utilizador, dados geográficos, resultados intermédios e métricas quantitativas utilizadas pelas fases de filtragem e ranking. A arquitetura assegura que o raciocínio do sistema é sequencial, auditável e modular.

2.1 Modelo Utilizado

O uso de um modelo **third-party**, concretamente o *llama-3.3-70b-versatile* disponibilizado através da **Groq API**, foi escolhido devido às exigências computacionais associadas à execução local de modelos de larga escala. A utilização de LLMs com dezenas de biliões de parâmetros requer hardware especializado — nomeadamente GPUs de

elevada capacidade ou aceleradores dedicados — cuja indisponibilidade inviabilizaria a operação em ambiente académico. A Groq API fornece **inferência altamente otimizada e de baixa latência**, garantindo tempos de resposta adequados ao funcionamento multi-agente sem comprometer a experiência do utilizador. Assim, a adoção desta solução externa permitiu equilibrar desempenho, custo e acessibilidade, mantendo a capacidade avançada de interpretação semântica essencial para o sistema.

2.2 Estrutura geral do sistema

O sistema é composto por cinco agentes especializados, cada um responsável por uma etapa distinta do pipeline de recomendação.

Planner Agent

O Planner recebe a consulta inicial e utiliza o LLM da Groq para extrair intenções, preferências explícitas e critérios subjetivos. Converte esta informação numa estrutura interna denominada **UserPreferences**, gerando um ficheiro JSON que serve de entrada para o Location Agent.

Location Agent

Este agente mapeia descrições subjetivas para regiões geográficas concretas. Para tal:

1. utiliza o LLM para interpretar atributos vagos (ex.: “ambiente calmo”);
2. consulta a base interna de localizações;
3. integra dados ambientais via Open-Meteo;
4. calcula um **location_score** para cada região candidata.

O resultado é um conjunto priorizado de identificadores geográficos.

Property Agent

Este agente consulta a **API do Idealista** para recolher imóveis nas localizações selecionadas. Em seguida aplica dois algoritmos clássicos:

1. **Constraint Satisfaction Problems (CSP)**: filtra rigorosamente imóveis que não satisfazem condições obrigatórias (preço máximo, tipologia, área, entre outros).
2. **A***: No caso de o utilizador especificar um serviço relevante (escola, hospital, ginásio), o agente executa o algoritmo **A*** para calcular o percurso ótimo entre cada imóvel e o ponto de interesse. O resultado é convertido num **A*_score**.

Após estes passos, o agente retém cerca de vinte imóveis compatíveis e envia-os ao Data Analyst Agent.

Data Analyst Agent

O Data Analyst Agent cria uma representação vetorial de cada imóvel utilizando atributos como:

- preço normalizado;
- área útil;
- distância ao serviço (via A*);
- pontuação CSP;
- características adicionais da API.

Aplica de seguida o algoritmo **K-Nearest Neighbors (KNN)** para identificar as propriedades mais similares ao perfil ideal do utilizador, selecionando as **três melhores**.

Evaluator Agent

O agente final sintetiza toda a informação previamente agregada. É responsável por:

- criar o **ranking final** de recomendações;
- justificar cada escolha com base em métricas explicáveis (CSP, A*, KNN);
- aplicar regras de anti-alucinação, garantindo que todas as recomendações são estritamente baseadas em dados obtidos.

2.3 Coordenação entre agentes

A coordenação segue o padrão **Round-Robin** fornecido pelo AutoGen:

Planner → Location → Property → Data Analyst → Evaluator

Este encadeamento garante previsibilidade, isolamento funcional entre agentes e controlo rigoroso da passagem de estado.

2.4 Integração dos algoritmos determinísticos

A abordagem neuro-simbólica integra três componentes determinísticos:

- **CSP** para filtragem rígida;
- **A*** para mobilidade e acessibilidade a serviços;
- **KNN** para ranking final por similaridade.

Estas técnicas complementam o LLM providenciado via Groq, proporcionando rigor matemático, reprodutibilidade e mitigação eficaz de alucinações.

2.5 Síntese da arquitetura

A arquitetura resultante conjuga:

- interpretação semântica via LLM (Groq API),
- raciocínio determinístico (CSP, A*, KNN),
- coordenação modular (AutoGen),
- e uma interface intuitiva construída em Streamlit.

Esta combinação permite ao sistema transformar preferências vagas em recomendações imobiliárias matematicamente consistentes, transparentes e centradas no utilizador.

3 Materiais e Detalhes Técnicos

Esta secção descreve os recursos técnicos, bibliotecas, serviços externos e componentes de software utilizados no desenvolvimento do Sistema Multi-Agente (SMA) de Recomendação de Imóveis. O objetivo é fornecer uma caracterização clara e reprodutível da infraestrutura tecnológica que suporta o sistema, assegurando transparência e consistência com as práticas de investigação em Inteligência Artificial.

3.1 Modelos, Frameworks e Infraestrutura de Inferência

O sistema recorre ao modelo **llama-3.3-70b-versatile**, disponibilizado por terceiros e acedido através da **Groq API**, beneficiando da inferência acelerada em hardware especializado. Este modelo desempenha funções de:

- interpretação de linguagem natural;
- análise e desambiguação de preferências subjetivas;
- apoio semântico às decisões dos agentes;
- conversão de descrições em linguagem natural para estruturas formais.

A coordenação multi-agente é assegurada pela framework **Microsoft AutoGen**, responsável por:

- gestão de ciclos de execução;
- troca estruturada de mensagens entre agentes;
- manutenção de um estado global partilhado;
- execução sequencial de agentes através do padrão **Round-Robin**;
- integração com APIs externas e ferramentas auxiliares.

3.2 Ferramentas Externas e Serviços Integrados

O sistema integra diversas APIs e bibliotecas, essenciais para a aquisição e processamento de informação:

- **API do Idealista** — fonte primária de listagens de imóveis em tempo real;
- **Open-Meteo API** — fornece dados ambientais e meteorológicos relevantes para o Location Agent;
- **geopy** — utilizada para cálculos geográficos de suporte ao sistema;
- **Groq API** — responsável pela execução do LLM com latência reduzida;
- **Streamlit** — usada para construir a interface de utilizador de forma simples e interativa.

3.3 Linguagens, Pacotes e Ambiente de Desenvolvimento

O projeto foi desenvolvido integralmente em **Python 3.13**, utilizando as seguintes bibliotecas principais:

- **autogen** → orquestração multi-agente;
- **requests** → comunicação com APIs externas;
- **scikit-learn** → implementação do algoritmo K-Nearest Neighbors (KNN);
- **pydantic / dataclasses** → modelação estruturada de dados;
- **numpy / pandas** → processamento e normalização de dados quantitativos;
- **geopy** → suporte geográfico geral (quando necessário).

Implementação manual do algoritmo A*

O algoritmo **A*** utilizado no sistema foi implementado manualmente, sem recurso a bibliotecas externas de grafos. Cada imóvel é tratado como um nó individual para o qual são calculados:

- **g(n)** — distância real ao serviço (Haversine);
- **h(n)** — heurística Euclidiana admissível;

- **f(n) = g(n) + h(n)** — custo total usado para ordenar os imóveis.

A priorização é realizada através de uma estrutura *heapq*, permitindo seleccionar rapidamente os imóveis com menor custo total. Esta implementação simples e eficiente adequa-se ao contexto do sistema, onde os imóveis não formam um grafo conectado, mas sim um conjunto de pontos geográficos independentes.

3.4 Estruturas de Dados e Representações Internas

A arquitetura assenta em estruturas conceptuais que representam o fluxo de informação entre agentes. Os nomes apresentados são abstratos e visam claridade académica, correspondendo às funções reais no sistema:

- **UserPreferences** — armazena preferências explícitas e subjectivas do utilizador;
- **LocationCandidates** — conjunto de localizações avaliadas com base em heurísticas ambientais;
- **PropertySet** — lista filtrada de imóveis após aplicação de CSP e cálculo de distâncias com A*;
- **FeatureVectors** — representação vetorial das propriedades para o algoritmo KNN;
- **FinalRecommendation** — resultado contendo o ranking e explicações associadas.

Estas estruturas asseguram modularidade e permitem auditoria em cada fase do pipeline.

3.5 Hardware e Considerações de Desempenho

A inferência linguística é delegada ao hardware especializado Groq, proporcionando:

- tempos de resposta reduzidos;
- diminuição da carga computacional local;
- maior escalabilidade do sistema.

Os componentes determinísticos — CSP, A* e KNN — são executados localmente, garantindo rigor matemático e controlo total sobre o pipeline analítico.

3.6 Reprodutibilidade e Controlo de Erros

O sistema incorpora:

- validações internas para detetar inconsistências;
- regras de anti-alucinação no Evaluator Agent;
- logging estruturado para facilitar depuração e análise;
- isolamento funcional entre agentes, permitindo rastreamento claro da origem de erros.

Estas medidas reforçam a fiabilidade e reprodutibilidade essenciais num sistema de recomendação inteligente.

Em conjunto, estes materiais formam a base técnica que sustenta o sistema, integrando de forma coesa técnicas determinísticas, modelos de linguagem avançados e serviços externos.

4 Experiências e Resultados

A avaliação do sistema multi-agente foi conduzida de forma controlada, através de um conjunto de cenários representativos que simulam pedidos reais feitos por potenciais compradores de imóveis. O objetivo não foi testar

exaustivamente todos os casos possíveis, mas sim demonstrar, de forma acadêmica e sistemática, **como o sistema reage a diferentes perfis de procura**, validando a coerência e robustez do seu funcionamento.

4.1 Metodologia de Teste

Os cenários avaliados incidiram sobre diferentes tipos de requisitos, permitindo observar o comportamento coordenado dos agentes:

- **Consultas com parâmetros completos**, onde o utilizador especifica tipologia, localização, requisitos adicionais e orçamento. (Ex.: “Quero comprar um T4 em Coimbra, habitável, com orçamento de 1.500.000€”).
- **Consultas com exigências ambientais ou geográficas**, que dependem da interpretação subjetiva do Location Agent. (Ex.: “Quero comprar um T4 num local com clima ameno e ao litoral”).
- **Consultas com proximidade a serviços específicos**, permitindo observar o uso do A* e das métricas de distância. (Ex.: “Quero um T2 em Lisboa perto do Hospital Lusíadas, com orçamento de 1.000.000€”).

Esta abordagem permite documentar o comportamento do sistema sem recorrer a longas listagens de output, centrando-se na forma como os agentes colaboram, verificam restrições e produzem recomendações justificadas.

4.2 Comportamento dos Agentes Durante os Testes

De forma consistente, observou-se:

- O **Planner Agent** extrai corretamente os elementos essenciais (tipologia, localização, requisitos adicionais e orçamento), validando a entrada do utilizador.
- O **Location Agent** traduz conceitos subjetivos (ex.: “ambiente calmo”, “zona rural”, “clima ameno”) em localizações reais, com base num modelo LLM e dados meteorológicos.
- O **Property Agent** interage com a API do Idealista aplicando filtros adequados ao orçamento e preferências, seguido da filtragem por CSP.
- O **Data Analyst** produz uma ordenação quantitativa robusta utilizando KNN com múltiplas features normalizadas.
- O **Evaluator Agent** sintetiza os resultados e produz recomendações justificadas e interpretáveis.

4.3 Discussão dos Casos Avaliados

Os três cenários modelo mostraram que:

1. **Consultas completas produzem resultados estáveis**, com boa coerência entre as preferências e os imóveis recomendados.
2. **Consultas com condições ambientais** mostram a capacidade do Location Agent de mapear descrições para zonas específicas, assegurando consistência geográfica.

3. **Consultas com proximidade a serviços** demonstram o correto funcionamento da integração entre CSP, A* e seleção final por KNN.

O comportamento consistiu em:

- Redução efetiva do espaço inicial de imóveis através do CSP.
- Priorização geográfica via A* quando aplicável.
- Recomendação final sensível às necessidades do utilizador graças ao modelo de ranking.

4.4 Limitações Observadas

Durante os testes identificaram-se limitações naturais ao problema e ao domínio:

- A API do Idealista nem sempre fornece propriedades com todas as características solicitadas (ex.: jardim).
- As descrições dos imóveis podem não mencionar atributos relevantes, levando o sistema a classificações menos precisas.
- Em casos onde várias propriedades satisfazem igualmente as preferências iniciais, os scores tendem a ser muito próximos, como observado no CSP e no KNN.
- O modelo LLM acedido via Groq API apresenta, ocasionalmente, limitações de *throughput*, originando erros de *rate-limit* em execuções repetidas. Estes episódios obrigam a pequenas pausas ou reenvio de pedidos, não afetando a lógica interna do sistema, mas introduzindo constrangimentos práticos quando são feitas múltiplas consultas num curto intervalo de tempo.

Estas limitações são inerentes aos dados e não ao sistema em si, que se comportou de forma coerente dentro das capacidades do repositório de imóveis disponível.

4.5 Conclusão da Avaliação

A avaliação experimental demonstra que o sistema multi-agente:

- Interpreta corretamente diferentes tipos de requisitos;
- Filtra e classifica propriedades com base em múltiplos critérios;
- Produz recomendações consistentes, justificadas e facilmente interpretáveis.

O sistema apresenta um comportamento robusto e alinhado com os objetivos definidos para o projeto.

5 Conclusão e Trabalho Futuro

5.1 Conclusão Geral

O projeto desenvolvido demonstra que um **Sistema Multi-Agente (SMA) neuro-simbólico** é uma abordagem eficaz para o problema de recomendação imobiliária, permitindo interpretar pedidos em linguagem natural, aplicar filtros determinísticos, recorrer a dados reais e produzir recomendações justificadas.

A combinação entre:

- **LLMs** (para interpretação semântica, extração de requisitos e análise subjetiva);

- **algoritmos clássicos de IA** (CSP, A*, KNN);
- **APIs e dados reais** (Idealista, geopy, Open-Meteo);

resultou num sistema equilibrado que evita alucinações típicas de modelos puramente generativos, mantendo a robustez estrutural dos métodos determinísticos.

Os testes realizados evidenciaram:

- Boa consistência entre requisitos e recomendações;
- Correção na deteção de constrangimentos essenciais (ex.: tipologia, localização, orçamento);
- Capacidade de interpretar condições ambientais subjetivas;
- Comportamento estável perante *queries* diversas, incluindo cenários ambientais e proximidade a serviços.

No geral, o sistema comportou-se de acordo com os objetivos definidos, demonstrando ser uma solução **funcional, explicável e extensível**.

5.2 Trabalho Futuro

Para melhorar o sistema, identificam-se as seguintes direções de evolução:

1. Integração de mais fontes de dados

- Bases de dados públicas (ex.: INE, OSM, dados de segurança, ruído, mobilidade).
- Dados de valorização imobiliária por zona.
- Mapas de proximidade real (transporte público, supermercados, escolas).

2. Melhorias nos algoritmos determinísticos

- Expandir o CSP com novos atributos e pesos (ex.: luminosidade, eficiência energética, ruído, acessibilidade) para melhorar a granularidade das recomendações.
- Extensão do A* para múltiplos serviços em simultâneo.

3. Aprimoramento do Location Agent

- Mapeamento mais fino entre descrições ambientais e clusters geográficos.
- Uso de embeddings para relação semântica entre zona e perfil desejado.

4. Interface mais interativa

- Capacidade de diálogo contínuo com o utilizador (follow-up questions).
- Visualização em mapa com marcadores dos imóveis recomendados.
- Score explicativo detalhado com slides e gráficos.

5. Modo de recomendação inteligente contínua

- Guardar preferências ao longo do tempo.
- Enviar alertas quando novas propriedades surgirem dentro do perfil.

5.3 Considerações Finais

O sistema proposto constitui uma **prova de conceito sólida** de como métodos neuro-simbólicos podem melhorar significativamente a pesquisa imobiliária tradicional. A arquitetura multi-agente demonstrou ser eficaz, modular, facilmente extensível e adaptada a cenários reais.

Com melhorias graduais nos dados, ontologias e na integração com modelos mais recentes, o sistema tem

potencial para evoluir para uma plataforma completa de recomendação imobiliária inteligente, eficiente e centrada no utilizador.